

Proyecto 1: Monitoreo transaccional

Detectar lo que el orden revela

Wilson Alejandro Calderón Argueta (22018) - Pablo Daniel Barillas Moreno (22193)
Universidad del Valle de Guatemala - Deep Learning y Sistemas Inteligentes - Kevin Recinos


Resumen ejecutivo

Se analizaron 590,540 transacciones IEEE-CIS, con 20,663 fraudes (3.499%). La comparación controlada enfrentó A (agregados + HistGradientBoosting), B (ocho eventos ordenados + GRU) y C (GRU + agregados). El candidato congelado fue A. B alcanzó AUC-PR 0.412; al permutar la historia obtuvo 0.410. La caída de 0.002 no demuestra valor material del orden. Recomendamos conservar A para priorizar revisión y no migrar todavía a secuencias.

1. Integridad de datos y protocolo temporal

Ruta B con IEEE-CIS Fraud Detection (Vesta Corporation). TransactionDT define el orden. La entidad se aproxima con card1+card2+card3+card5+addr1; puede mezclar o fragmentar clientes. Cada objetivo usa su transacción actual y hasta siete antecedentes, nunca eventos futuros. Imputación, escalado y vocabularios se ajustan exclusivamente con entrenamiento. El submuestreo computacional conserva todos los positivos y ocurre solo dentro del 70% inicial.

Partición	n	Tasa de fraude
Entrenamiento poblacional	413,378	3.517%
Validación	88,581	3.434%
Prueba final	88,581	3.480%



2. Núcleo común A-B y apuesta C

Pieza	Entrada y modelo	Control / propósito
A - sin orden	Agregados invariantes a la permutación + HistGradientBoosting	Representa el sistema competitivo sin leer la secuencia
B - secuencial	10 variables numéricas, 6 categóricas, embeddings + GRU(32)	Puede explotar transiciones y dependencia temporal
C - apuesta	Estado final GRU concatenado con agregados estandarizados	Prueba si la información global complementa la secuencia


Hipótesis previa

Creemos que fusionar la representación secuencial de la GRU con variables agregadas mejorará el AUC-PR porque la evidencia temporal y global es complementaria. Lo consideraremos útil si aumenta AUC-PR al menos 0.01 y reduce el costo al menos 5% en validación. Resultado en validación: Delta AUC-PR -0.001; reducción de costo 0.3%. No cumplió ambos criterios.

3. Comparación común en prueba cronológica


Modelo	AUC-PR	Precisión	Recall	F1	Costo
A	0.429	0.134	0.722	0.226	Q6,193,620
B	0.412	0.154	0.649	0.248	Q6,525,960
C	0.392	0.136	0.671	0.226	Q6,618,900

AUC-PR es la métrica principal por el desbalance. Precisión, recall y F1 se calculan con el umbral económico elegido solo en validación; exactitud no interviene.




4. Valor del orden: intentos de refutación

Permutación controlada: se barajó cinco veces solo la historia válida y se mantuvo la transacción objetivo al final. B obtuvo AUC-PR 0.412 original y 0.410 +/- 0.001 permutada. La caída fue 0.002, inferior al criterio previo de 0.01. Segunda prueba: al conservar solo los tres eventos más recientes, AUC-PR fue 0.411. Conclusión honesta: este experimento no demuestra aporte material del orden.



5. Umbral y decisión económica

Se minimizó $C(\tau) = Q4,200 \cdot FN + Q180 \cdot FP$ en validación. En prueba, A cuesta Q6,193,620 (Q6,992,041 por 100 mil decisiones). Con 1.4 millones de tarjetas y 12 transacciones mensuales, A escala a Q1,174,662,919/mes. Frente a A, B perdería Q63,030,582/mes y C Q80,657,297/mes. Es un escenario académico; prevalencia, volumen y costos reales deben sustituir estos supuestos.



6. Recomendación, patrón de error y límites

Conservar A y usar el puntaje para priorizar revisión, no para bloquear automáticamente. No hay evidencia suficiente para reemplazar el motor agregado con B o C. Patrón concreto: 222 de 858 falsos negativos de A (25.9%) pertenecen a ProductCD=W y al intervalo de monto (68.5, 117.0]. La concentración es descriptiva, no causal. La recomendación cambiaría con una identidad de tarjeta confiable, una cohorte posterior donde B/C reduzcan costo y una capacidad operativa capaz de absorber alertas.

Límites principales

Identidad aproximada; atributos anonimizados; solo 182 días; ventana máxima de ocho eventos; costos transferidos; sin piloto humano, latencia, deriva, equidad ni calibración externa. El benchmark no debe interpretarse como causalidad ni como autorización para acusar o bloquear clientes.

Patrones de error observados

Tipo	Segmento descriptivo	n	Lectura operativa
FN	ProductCD=W; monto (68.5, 117.0]	222	25.9% de los FN del candidato
FP	ProductCD=W; monto (117.0, 5366.82]	4,180	Mayor presión sobre revisión manual

Uso de IA

Se usó IA para estructurar código, revisar consistencia, apoyar redacción y diseño. Los autores verificaron datos, partición, construcción causal de ventanas, métricas, falsificaciones, umbral y archivos finales. La IA no se considera fuente académica.

Matriz de evidencias

Evidencia	Figura o tabla	Conclusión	Limitación
Integridad de datos	Fig. 1 y tabla de particiones	70/15/15 cronológico; ajustes train-only	Entidad aproximada
Comparación A-B	Fig. 2 y tabla A/B/C	A supera a B en AUC-PR y costo	Historial máximo de 8 eventos
Valor del orden	Fig. 3	Permutación y recorte no causan caída material	Proxy de identidad puede diluir señal
Apuesta C	Hipótesis y tabla de validación	C no cumple DeltaAP ni reducción de costo	Mayor complejidad y una semilla
Economía	Fig. 4 y comparación mensual	A minimiza el costo bajo Q4,200/Q180	Volumen, prevalencia y costos asumidos
Recomendación	Sección 6	Conservar A; secuencias quedan en investigación	Falta piloto productivo

Referencias

Cho, K., et al. (2014). Learning phrase representations using RNN encoder-decoder. arXiv:1406.1078.
IEEE Computational Intelligence Society. (2019). IEEE-CIS Fraud Detection [Data set]. Kaggle.
Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. PLOS ONE, 10(3), e0118432.
Scikit-learn Developers. Common pitfalls and recommended practices.

Decisión para el comité

El orden es una hipótesis valiosa, pero con esta identidad aproximada y este horizonte no genera valor incremental demostrable. Conservar A, recopilar una clave de tarjeta confiable y repetir la prueba en una cohorte futura.