

DEEP LEARNING Y SISTEMAS INTELIGENTES

Proyecto 1

Monitoreo transaccional — V3

LightGBM nativo, recencia y validación temporal

Universidad del Valle de Guatemala
Kevin Recinos · Grupo 1 · Sección 30
Semestre II 2026

Wilson Alejandro Calderón Argueta · 22018
Pablo Daniel Barillas Moreno · 22193

Estado: V3 promovida por cuatro criterios. Benchmark final histórico reutilizado.

Resumen ejecutivo

Se analizaron 590,540 transacciones IEEE-CIS con prevalencia 3.50

1 Datos, identidad y fuga

Las tablas se unen con TransactionID y ordenan con TransactionDT; ninguna entra como magnitud predictiva. Para cada t , $x_t^{hist} = f(\{x_j : t_j < t\})$. Se crean conteos previos, media/desviación de monto, razón de monto, tiempo desde operación anterior y actividad 1/6/24/72 h. La clave de tarjeta–dirección genera 42,946 proxies; puede mezclar o fragmentar usuarios. El protocolo usa 70% train, 15% validación y 15% benchmark reutilizado.

2 Selección y modelos

Correlación e información mutua se aprenden en el 55% inicial. Se excluyen IDs, constantes y ausencia extrema; la poda $|\rho_s| \geq 0.995$ solo elimina sustitutos casi monotónicos. LightGBM usa categorías nativas y NaN; se comparan pesos uniformes, vida media de 75 días y 300k recientes. Como control se ajustan logísticas L2, L1, Elastic Net y PCA64. Las tres variantes SAGA no convergieron en 100 iteraciones y se tratan como baselines diagnósticos.




Figure 1: Comparación walk-forward de V3.

3 Validación temporal

Las AP medias fueron 0.5809 con recencia, 0.5735 uniforme y 0.5679 con 300k recientes. Recencia gana los tres folds. Frente a V2, el aumento medio es 0.1082; por tanto, supera el mínimo predefinido de 0.015 sin depender de un solo corte. PCA64 explica 99.53% de varianza y obtiene AP 0.3032, mientras Elastic Net obtiene 0.3312. Esto confirma que conservar varianza no equivale a conservar señal supervisada y que el problema necesita interacciones no lineales.

4 Resultados y promoción

Versión	AUC-PR	Prec.	Recall	F1	Costo
V1	0.429	0.134	0.722	0.226	Q6,193,620
V2	0.454	0.149	0.703	0.246	Q6,078,120
V3	0.513	0.190	0.727	0.302	Q5,250,540

La promoción no usa el benchmark: exige AP walk-forward $+0.015$, costo holdout -3% , recall dentro de un punto y ganar al menos dos folds. V3 cumple los cuatro. En el benchmark reutilizado, la diferencia pareada AP es 0.0589, IC descriptivo $[0.0431, 0.0748]$.




Figure 2: Curvas PR en benchmark histórico reutilizado.

5 Calibración y umbrales

La validación se divide cronológicamente para early stopping, calibración y selección de umbral. La calibración reduce Brier de 0.0206 a 0.0206 y ECE de 0.0068 a 0.0047.

El umbral balanceado 0.05220 maximiza F1 con recall mínimo 70%; mejora simultáneamente todas las métricas frente a V2. El umbral económico 0.03164 minimiza $4200FN + 180FP$: alcanza recall 0.811 y costo Q5,168,040, pero genera más alertas y menor precisión.




Figure 3: Frontera entre recall y costo en el holdout.

6 Operación, límites y ética

Al revisar el 1% de mayor riesgo, precisión es 88.25% y recall 25.33%. Se reportan segmentos de producto, dispositivo, monto e historia con el candidato recomendado. El prototipo prioriza revisión humana; no bloquea transacciones ni atribuye culpabilidad.

Limitaciones: benchmark reutilizado, identidad proxy, anonimización, 182 días y costos académicos. Antes de producción se requieren cohorte nueva, privacidad, seguridad, explicabilidad, sesgo, costos reales, latencia y monitoreo de deriva. La GRU no se amplió porque la falsificación V1 no mostró señal de orden suficiente.

7 Conclusión

V3 mejora de manera significativa y consistente. El salto se atribuye a cobertura ampliada, categorías nativas, ausencia preservada y recencia; regresión logística y PCA no sustituyen las interacciones del árbol. V1/V2 pueden retirarse del árbol activo porque Git conserva su historia y V3 mantiene referencias mínimas para auditoría.

Referencias

- IEEE Computational Intelligence Society. (2019). *IEEE-CIS Fraud Detection*. Kaggle.
- Ke, G., et al. (2017). LightGBM. *NeurIPS*, 30.
- Saito, T., & Rehmsmeier, M. (2015). Precision-recall plots for imbalanced data. *PLOS ONE*, 10(3), e0118432.
- Scikit-learn developers. (2026). *LogisticRegression; Probability calibration*.

Declaración de IA

IA apoyó código, redacción, visualización y auditoría. Los autores ejecutaron, verificaron y asumen responsabilidad.