

DEEP LEARNING Y SISTEMAS INTELIGENTES

Proyecto 1

Monitoreo transaccional — V4

Ingeniería causal, expertos y validación temporal

Universidad del Valle de Guatemala
Kevin Recinos · Grupo 1 · Sección 30
Semestre II 2026

Wilson Alejandro Calderón Argueta · 22018
Pablo Daniel Barillas Moreno · 22193

Estado: candidato congelado post-hoc; V3 permanece confirmada hasta una cohorte nueva.

Resumen ejecutivo

Se analizaron 590,540 transacciones IEEE-CIS con prevalencia 3.50%. V4 integra 569 columnas tras ingeniería y selecciona 360 numéricas más 38 categóricas. LightGBM optimizado alcanza AP walk-forward 0.6175 y ROC-AUC media 0.9220. El candidato experto por ProductCD, seleccionado antes de calibración y evaluación, obtiene AP 0.5491, ROC-AUC 0.9012, precisión 0.2024, recall 0.7652, F1 0.3201 y costo Q605,520. Mejora todas las métricas frente a V3, pero la política recall ≥ 0.75 es post-hoc; requiere cohorte nueva.

1 Problema y datos

El fraude representa 3.50%; accuracy convencional sería engañosa. Se priorizan AUC-PR, precisión, recall, F1, costo y top-K. Las tablas se unen con TransactionID y ordenan con TransactionDT; ninguno entra como magnitud predictiva. Para cada transacción, $x_t^{hist} = f(\{x_j : t_j < t\})$. Se utiliza 70% train, 15% validación y 15% benchmark histórico reutilizado.

2 Ingeniería causal

V4 añade calendario, forma del monto, resúmenes V/C/D, $D_i - da$, $\log(1 + C_i)$, ausencias, frecuencias previas, cambios de contexto y estadísticas para tarjeta–dirección, tarjeta–correo, tarjeta–dispositivo y tarjeta–producto. IDs no se usan como números continuos. Selección y correlación se aprenden en el 55% inicial; solo se podan sustitutos con $|\rho_s| \geq 0.999$. PCA no se aplica al boosting porque en V3 perdió AP aun conservando 99.53% de varianza.

3 Modelos y protocolo

Optuna ejecuta 18 pruebas sobre hojas, profundidad, regularización, submuestreo y suavizado categórico. Se comparan LightGBM, XGBoost y CatBoost piloto, hard-negative mining, expertos W/NO-W y stacking. CatBoost y XGBoost usan 120/220 iteraciones por costo de CPU; son ablations, no búsquedas exhaustivas. La validación se divide para early stopping, meta, selección de candidato, calibración, umbral y evaluación.




Figure 1: AUC-PR walk-forward de candidatos V4.

LightGBM obtiene AP media 0.6175 (DE 0.0412), mejora V3 en 0.0366 y supera 0.90 de ROC-AUC media. XGBoost obtiene 0.5957 y CatBoost piloto 0.5302. La ventaja de LightGBM aumenta cerca del periodo final.

4 Selección y resultados

El bloque 50–60% de validación selecciona el candidato antes de calibración y umbral. Expertos ProductCD ganan con AP 0.6078; stacking obtiene 0.6007, pero reduce ROC-AUC de evaluación a 0.8686 y se descarta.

Modelo	AUC-PR	ROC-AUC	Prec.	Recall	F1	Costo
V3	0.445	0.890	0.163	0.710	0.265	Q743,280
V4	0.549	0.901	0.202	0.765	0.320	Q605,520

V4 aumenta AP 0.1041, ROC-AUC 0.0112, precisión 0.0397, recall 0.0556 y F1 0.0554; reduce costo 18.5%. La diferencia pareada AP es 0.1041, IC 95% [0.0696, 0.1426].




Figure 2: Curvas PR V3/V4 en benchmark histórico reutilizado.

5 Calibración, umbral y capacidad

La calibración del candidato reduce Brier de 0.0245 a 0.0237 y ECE de 0.0156 a 0.0060. El umbral robusto 0.05664 exige recall 0.75 en selección para amortiguar deriva y el costo FN/FP de 23.3:1.

La política balanceada prioriza F1; la económica eleva recall a 0.813, pero baja precisión. En el benchmark V4 obtiene AP 0.5592, ROC-AUC 0.9013, precisión 0.2152, recall 0.7399 y costo Q4,866,000. Al revisar 1% de mayor riesgo, precision@K supera 0.90 y recall@K ronda 0.26.




Figure 3: Selección del candidato en bloque independiente.

6 Deriva, limitaciones y decisión

La validación adversarial alcanza ROC-AUC 1.0, dominada por `day_index` y acumulados; demuestra separación temporal y justifica `walk-forward`, no perfección del fraude. Deben separarse deriva total y residual sin tiempo explícito en una cohorte futura.

Limitaciones: benchmark reutilizado, identidad proxy, datos anonimizados, costos académicos, presupuesto piloto CatBoost/XGBoost y ausencia de cohorte externa. V4 no debe bloquear transacciones ni atribuir culpabilidad; prioriza revisión humana. Antes de producción se requieren privacidad, seguridad, explicabilidad, sesgos, costos reales, latencia, monitoreo y apelación.

Decisión: V4 domina V3 bajo la política robusta, pero esa política fue añadida después de observar la primera evaluación. Se congela el pipeline, las 398 variables, los modelos, calibrador y umbral; V3 permanece confirmada hasta evaluar V4 una sola vez y sin ajustes en una cohorte temporal nueva.

Referencias

- Akiba, T., et al. (2019). Optuna. *KDD*, 2623–2631.
Chen, T., & Guestrin, C. (2016). XGBoost. *KDD*, 785–794.
IEEE CIS. (2019). *IEEE-CIS Fraud Detection*. Kaggle.
Ke, G., et al. (2017). LightGBM. *NeurIPS*, 30.
Prokhorenkova, L., et al. (2018). CatBoost. *NeurIPS*, 31.
Saito, T., & Rehmsmeier, M. (2015). Precision-recall plots for imbalanced data. *PLOS ONE*, 10(3).

Declaración de IA

IA apoyó código, redacción, visualización y auditoría. Los autores ejecutaron, verificaron y asumen responsabilidad.