

DEEP LEARNING Y SISTEMAS INTELIGENTES

Proyecto 1

Monitoreo transaccional

Detectar lo que el orden revela · V5 integrada

Universidad del Valle de Guatemala
Kevin Recinos · Grupo 1 · Sección 30
Semestre II 2026

Wilson Alejandro Calderón Argueta · 22018
Pablo Daniel Barillas Moreno · 22193

Decisión: conservar A para priorizar revisión humana; la evidencia no demuestra valor material del orden.

Resumen ejecutivo

Se estudiaron 590,540 transacciones IEEE-CIS (3.50% fraude). La investigación compara A, LightGBM sin lectura secuencial; B, GRU causal de 16 eventos; y C, fusión A+B. En evaluación interna, A obtiene AP 0.5445, B 0.4245 y C 0.5425. A minimiza costo (Q1,067,460) y queda como candidato. Permutar B cambia AP de 0.4245 a 0.4355; no se atribuye valor al orden. El benchmark es histórico reutilizado, no test ciego.

1 Integridad de datos

Las tablas IEEE-CIS se unen por TransactionID y ordenan por TransactionDT; ambos se excluyen como magnitudes. La identidad proxy combina card1, card2, card3, card5 y addr1. Cada secuencia contiene la transacción objetivo y hasta 15 antecedentes; 76.3% tiene longitud al menos 8 y 66.2% llega a 16. La división es 70% entrenamiento, 15% validación y 15% benchmark histórico. Imputación, escalado, categorías y umbrales se aprenden antes del bloque evaluado. Toda variable histórica cumple $x_t^{hist} = f(\{x_j : t_j < t\})$.




Figure 1: Comparación común A/B/C en evaluación interna temporal.

2 Núcleo A/B y apuesta C

A reutiliza LightGBM V4 con expertos W/NO-W y agregados causales. **B** emplea 57 numéricas, 12 categóricas con embeddings, proyección de 96, GRU(64), BCE ponderada, AdamW y early stopping sobre las 413,378 filas de entrenamiento. Ambos producen riesgo continuo sobre las mismas filas. **C** combina logits A/B, monto, longitud y producto mediante regresión logística ajustada en un bloque separado.

Hipótesis previa: fusionar A+B será útil si aumenta AP al menos 0.01 y reduce costo al menos 5% frente al mejor modelo individual. C obtiene cambio AP -0.0020 y reducción de costo -0.43%; el veredicto es **no útil**.

Modelo	AP	ROC	Prec.	Recall	F1	Costo
A	0.545	0.908	0.220	0.738	0.339	Q1,067,460
B	0.424	0.877	0.132	0.749	0.224	Q1,320,840
C	0.542	0.911	0.173	0.785	0.284	Q1,072,020

3 Valor del orden

La permutación baraja solo los antecedentes, conserva eventos, variables agregadas y transacción objetivo, y se repite cinco veces. B original obtiene AP 0.4245; permutada, 0.4355 ± 0.0021 . La diferencia original-permutada es -0.0111. Recortar a 3 eventos produce 0.4253; usar 8 produce 0.4225. Destruir o reducir la historia no ocasiona una caída material: no puede afirmarse que el orden aporte.




Figure 2: Permutación controlada y segunda prueba de falsificación.

La caída de B entre evaluación interna y benchmark (AP 0.424 a 0.218) revela sensibilidad temporal. Una secuencia más rica no garantiza estabilidad si la identidad es aproximada.

4 Umbral y valor económico

La política predefinida minimiza $4200FN + 180FP$ sujeto a $\text{recall} \geq 0.75$ en el bloque de umbral. A usa $\tau = 0.05783$. En benchmark histórico logra AP 0.5592, precisión 0.2215, recall 0.7327, F1 0.3402 y costo Q4,890,000.

Modelo	Costo 12 tx/tarjeta/mes	Ahorro vs. A	Alertas/100k
A	Q927,422,359	Q0	11,514
B	Q1,092,992,854	Q-165,570,495	21,934
C	Q943,103,194	Q-15,680,834	17,197

La proyección usa 1.4 millones de tarjetas y escenarios 5/12/20 transacciones por tarjeta; no es una cifra contable. Ahorros negativos representan pérdidas frente a A.




Figure 3: Costo de los tres modelos en evaluación interna.

5 Recomendación, errores y límites

Se recomienda **conservar y complementar** el sistema tabular con A para ordenar revisión humana. No se recomienda migrar a B ni bloquear automáticamente. Los falsos negativos de monto alto son el error prioritario; se exportan cien casos para análisis. La recomendación cambiaría si una identidad fiable causara una caída material al permutar, una cohorte nueva favoreciera B/C o la operación no absorbiera las alertas.

Límites: benchmark reutilizado, identidad proxy, anonimización, 182 días, costos académicos, deriva y ausencia de privacidad, equidad, seguridad, explicaciones, latencia y apelación. Antes de producción se requiere cohorte temporal nueva y piloto humano.

Tres decisiones defendibles

(1) LightGBM V4 reemplaza HGB V1 por cobertura y costo; (2) GRU se prefiere a Transformer/TCN por eficiencia y falsabilidad; (3) stacking tardío reemplaza el híbrido interno para aislar aportes. Ninguna decisión usa accuracy ni partición aleatoria.

Referencias

- Cho, K., et al. (2014). GRU encoder–decoder. *EMNLP*, 1724–1734.
- IEEE CIS. (2019). *IEEE-CIS Fraud Detection*. Kaggle.
- Ke, G., et al. (2017). LightGBM. *NeurIPS*, 30.
- Saito, T., & Rehmsmeier, M. (2015). Precision–recall plots for imbalanced data. *PLOS ONE*, 10(3).

Matriz de evidencias

Evidencia	Ubicación	Conclusión	Limitación
Integridad Comparación A/B	Sección 1, Fig. 1 Tabla A/B/C	70/15/15 temporal y train-only A domina AP, F1 y costo	Identidad aproximada A posee más ingeniería
Valor del orden	Fig. 2	Permutar no reduce AP	Una GRU y una clave
Apuesta C	Sección 2	No alcanza criterio previo	Fusión logística específica
Decisión económica	Sección 4, Fig. 3	A minimiza costo interno	Costos y volumen académicos
Recomendación	Sección 5	Complementar con revisión	Requiere cohorte nueva

Declaración de IA. Se usó asistencia para código, redacción, visualización y auditoría. Los autores ejecutaron y verificaron datos, métricas, falsificaciones y conclusiones.