

Monitoreo transaccional

Evidencia del valor del orden y detección de anomalías

Pregunta ejecutiva

¿El orden, una arquitectura secuencial o un encoder-decoder detectan fraude mejor que un baseline tabular competitivo?			
590,540	3.50%	0.559	0.807
transacciones	fraude	AP A histórico	recall A histórico

Decisión: conservar A

A mantiene el mejor soporte interno para la decisión. C no cumple su regla previa; B no demuestra valor del orden; D detecta anomalías con demasiadas falsas alarmas. El benchmark se reporta descriptivamente, no se usa para reescribir el veredicto.

calidad del experimento depende más de causalidad, identidad y representación que del tamaño de la red.

Conclusión. Se usaron todas las 590,540 transacciones. Los IDs son llaves, no predictores; las variables históricas excluyen el evento actual y las transformaciones se ajustan solo con train.

Fuente y población

Los datos proceden de IEEE–CIS Fraud Detection en Kaggle, con transacciones anonimizadas suministradas por Vesta Corporation. `TransactionID` une las tablas y `TransactionDT` define el reloj. Hay 20,663 fraudes y prevalencia 3.50%.

Diagnóstico exploratorio

El cuaderno EDA audita faltantes, constantes, asociación con fraude, Spearman, PCA, deriva y cobertura de identidad. Encontró alta redundancia en el bloque V, pero PCA no se promueve por varianza explicada: en V3 redujo desempeño y puede borrar señal minoritaria. Se conservan variables por validación predictiva y estabilidad.

Identidad proxy

La entidad `card1+card2+card3+card5+addr1` permite construir historia, pero puede mezclar clientes o fragmentar uno. La cobertura alcanza 76.3% con al menos 8 eventos, 66.2% con 16 y 55.3% con 32.

Causalidad

Para una transacción t , toda estadística satisface $x_t^{hist} = f(\{x_j : t_j < t\})$. Se añadieron conteos y montos de 1/6/24/72 horas, cambios de dispositivo/dirección, monto relativo, faltantes y variables C/D/V/identidad. No se usa partición aleatoria.

Bloques cronológicos dentro del desarrollo

Bloque	Fracción	Uso	Control
Train	70% total	Preprocesamiento y modelos base	Nunca observa validación
Early	0–35% val	Early stopping de B/D	Anterior a toda selección
Meta fit	35–50% val	Controles/refuerzo A	No toca evaluación
Model select	50–60% val	Selección A y B; ajuste C	A usa dos subventanas de estabilidad
Calibración	60–70% val	Probabilidades	Separada del umbral
Umbral	70–80% val	Costo con recall objetivo	Regla congelada
Evaluación	80–100% val	Veredicto V6	No ajusta modelos
Benchmark	15% total	Referencia histórica reutilizada	No es test ciego

Integridad. Imputación, escalado y vocabularios se aprenden con train. El benchmark ya fue observado en V1–V5; una confirmación exige una cohorte futura.

2 · Núcleo A/B, apuesta C y control D


A/B/C

usan las mismas filas, etiqueta, horizonte y puntajes continuos; D se añade como control de anomalía.

Diseño	Qué prueba	Selección/entrenamiento
A	LightGBM V4 y re- fuerzo causal	Se conserva A_V4; el refuerzo no gana ambas subventanas
B	Embeddings + GRU o TCN causal	B_TCN gana en model select
C	Logística sobre A/B/D y calidad	Regla previa: +0.01 AP, -5% costo, recall $\geq$.75
D	Autoencoder de legí- timas	Solo isFraud=0 de train


Resultado común en evaluación interna

Modelo	AP	ROC	Prec.	Recall	F1	Costo	Alertas/100k
A	0.536	0.901	0.147	0.803	0.249	Q904,620	16,741
B	0.392	0.853	0.111	0.713	0.192	Q1,215,540	19,761
C	0.519	0.902	0.165	0.774	0.273	Q898,920	14,365
D	0.217	0.758	0.054	0.744	0.101	Q1,852,080	42,056



AP resume precisión al recorrer recall y es principal por el desbalance. **ROC–AUC** mide ordenamiento positivo–negativo, pero una tasa pequeña de FP aplicada a muchos legítimos todavía genera miles de alertas. **Precisión** es pureza de alertas; **recall** es cobertura de fraude; **F1** no incorpora quetzales. A logra AP 0.536. C mejora precisión y F1 frente a A, pero pierde AP; D alcanza recall 0.744 a costa de precisión 0.054. Ese patrón confirma que detectar rareza no basta.

Conclusión. A conserva el ranking más defendible. C compra eficiencia de alertas, pero no alcanza el criterio congelado. D produce demasiadas falsas alarmas para ser candidato.



Falsificación 1 · permutación controlada

Se conserva la transacción objetivo al final y se barajan únicamente sus antecedentes, con cinco semillas. La diferencia original–permutada es -0.0101 AP. Como es negativa, destruir el orden mejora el ranking promedio; no se alcanza la caída material positiva predeclarada de 0.01.

Falsificación 2 · longitud de historia

Recortar a 3, 8 o 16 eventos tampoco revela una ventaja creciente y estable. La ventana completa de 32 no domina claramente a las variantes cortas. Esto es coherente con una identidad proxy ruidosa: más eventos pueden añadir operaciones de otra persona o patrones legítimos no transferibles.

Interpretación

B sí contiene información predictiva: AP 0.392 supera ampliamente la prevalencia. Lo que falla es la afirmación causal estrecha de que el *orden* explica esa utilidad. B puede apoyarse en el evento actual, composición del historial y variables agregadas por evento.

Pregunta	Resultado	Conclusión permitida
¿B predice mejor que azar?	Sí, AP mayor que prevalencia	B aprende señal
¿B supera A?	No, pierde 0.145 AP	A sigue siendo más competitivo
¿B usa favorablemente el orden?	No; permutar aumenta AP	No atribuir valor material al orden
¿Más historia ayuda?	Sin patrón monotónico	No aumentar longitud sin mejor identidad

Conclusión. La prueba principal es negativa y concluyente dentro del alcance: con esta identidad, representación y arquitectura, el orden no aporta señal incremental demostrable.

desbalance motiva modelar normalidad; la validación decide si la anomalía coincide con fraude.

Diseño de D

El encoder comprime las variables numéricas estandarizadas y el decoder reconstruye la transacción. Se entrena únicamente con legítimas de train y minimiza

$$\mathcal{L}_{AE} = \frac{1}{p} \sum_{j=1}^p (x_j - \hat{x}_j)^2.$$

El MSE final sobre legítimas tempranas es 0.0382. El error se transforma en percentil frente a 120 mil errores legítimos de referencia y luego se calibra.

Qué obtuvo D

Internamente, D logra ROC 0.758 y recall 0.744, pero AP 0.217,


precisión 0.054 y 42,056 alertas/100k. Muchos eventos legítimos raros parecen anomalías; faltantes y deriva también elevan reconstrucción.

Apuesta C

C recibe logits A/B/D, calidad de historia, identidad disponible, monto, longitud, producto y faltantes. Se ajusta en model select, se calibra después y nunca observa evaluación al aprender pesos.

Veredicto congelado

Frente a A, C cambia AP en -0.0170, reduce costo 0.63% y alcanza recall 0.774. Requería +0.01 AP, -5% costo y recall $\geq .75$. Solo cumple recall: **C no es útil según su hipótesis.**




Calibración. Un score de ranking no es automáticamente una probabilidad. Cada modelo usa calibración logística en un bloque separado. Se compara Brier antes/después; el umbral económico se fija en el bloque siguiente.

Lectura responsable. El autoencoder es una ablation informativa, no un fracaso inútil: demuestra que la clase legítima es multimodal y temporalmente cambiante. Para mejorarlo se requerirían autoencoders por segmento, pérdidas robustas, categorías embebidas y validación de deriva; no basta aumentar capas.

No seleccionar con el benchmark. Aunque C aparece descriptivamente competitivo en el período histórico final, la hipótesis se juzga en evaluación interna y permanece rechazada.

costo hace explícito el intercambio: un falso negativo vale 23.3 veces un falso positivo.

$$C(\tau) = Q4,200\, FN(\tau) + Q180\, FP(\tau).$$



A usa $\tau = 0.03622$. En evaluación interna detecta 437 fraudes, omite 107 y produce 2529 falsas alarmas. Su costo es Q904,620, menor que B y D; C cuesta Q898,920, pero no cumple el criterio de ranking. El recall alto de A (80.3%) implica precisión moderada (14.7%). No es contradicción: la política acepta falsas alarmas porque FN cuesta 23.3 veces FP.

Benchmark temporal histórico reutilizado

Modelo	AP	ROC	Prec.	Recall	F1	Costo	Alertas/100k
A	0.559	0.901	0.158	0.807	0.264	Q4,889,400	17,801
B	0.465	0.877	0.123	0.785	0.212	Q5,898,960	22,264
C	0.563	0.907	0.171	0.798	0.282	Q4,753,500	16,207
D	0.229	0.769	0.056	0.824	0.105	Q9,977,040	51,137

Qué significan las cifras

A alcanza AP 0.559 y ROC 0.901: ordena razonablemente el riesgo, pero solo 15.8% de sus alertas es fraude. Detecta 80.7% de fraudes y genera 17,801 alertas por 100 mil. C luce mejor en AP histórico, pero esa observación es exploratoria; promoverlo ahora reutilizaría el benchmark.

Errores y sensibilidad

Los falsos negativos de mayor monto se guardan para revisión. La proyección mensual usa 1.4 millones de tarjetas y escenarios 5/12/20 transacciones por tarjeta; no es una cifra contable. Cambios en costo FN/FP o capacidad de analistas pueden mover el umbral sin modificar AP.

Conclusión. Las métricas son defendibles, no perfectas: A prioriza fraude mejor que azar y cubre cerca de 81%, pero la baja precisión confirma una carga relevante de falsas alarmas.

afirmación se vincula con una prueba y declara qué evidencia podría cambiarla.

Evidencia	Artefacto	Conclusión	Limitación
Integridad	EDA, particiones, contrato	590,540 filas; causalidad y train-only	Identidad aproximada
A/B común	Figura 1 y scores	A supera B en AP y costo	Ingeniería de A más rica
Valor del orden	5 permutaciones; 3/8/16	Permutar no perjudica; sin evidencia de orden	Una proxy y dos arquitecturas
Apuesta C	JSON de hipótesis	No alcanza +0.01 AP ni 5% ahorro	Fusión logística específica
Encoder-decoder	Checkpoint y score D	Anomalía tiene recall, no precisión	Normalidad multimodal y deriva
Economía	Curvas y Figura 4	A minimiza costo entre candidatos válidos	Costos/volumen académicos
Recomendación	Contrato/manifiesto	Conservar A como candidato V6	Confirmar en cohorte futura

Decisión concluyente

Conservar A. No promover B porque no supera A ni demuestra valor del orden. No promover C porque incumple la hipótesis previa, aunque el benchmark motive investigarlo en una cohorte nueva. No promover D porque su precisión y costo son inaceptables. La siguiente iteración debe priorizar identidad bancaria fiable, variables categóricas completas, validación walk-forward y una nueva cohorte etiquetada.

Qué cambiaría la decisión

(1) caída $AP \geq 0.01$ al permutar con una identidad fiable; (2) C cumpliendo simultáneamente ganancia AP, ahorro y recall en ventanas walk-forward; (3) D reduciendo alertas sin perder cobertura; (4) costos operativos reales que cambien el umbral; (5) estabilidad en una cohorte futura congelada.

Límites

Datos anonimizados; identidad proxy; benchmark reutilizado; costo académico; sin auditoría productiva de privacidad, equidad, explicabilidad, deriva, seguridad adversarial ni latencia. Los scores indican riesgo estadístico, no certeza de fraude.

Uso de inteligencia artificial

Se utilizó asistencia de IA para estructurar código, revisar consistencia, diseñar visuales y redactar documentación. Los autores ejecutaron el pipeline, verificaron IDs, particiones, métricas, falsificaciones, artefactos y conclusiones, y deben poder defender las decisiones.

Referencias APA 7

IEEE Computational Intelligence Society. (2019). *IEEE-CIS Fraud Detection* [Data set]. Kaggle. <https://www.kaggle.com/competitions/ieee-fraud-detection/overview>

Ke, G., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>

Zhou, C., & Paffenroth, R. C. (2017). Anomaly detection with robust deep autoencoders. *Proceedings of KDD*, 665-674. <https://doi.org/10.1145/3097983.3098052>