

Monitoreo transaccional

Evidencia temporal, detección de fraude y decisión económica

Pregunta ejecutiva

¿El orden de las transacciones o una arquitectura secuencial aportan señal incremental frente a un baseline tabular competitivo, y cuánto vale esa diferencia al considerar falsas alarmas y fraude omitido?

590,540

transacciones

3.50%

prevalencia

0.547

AP interna A5

Q826,800

costo interno A5

Resultado concluyente. A5, un stacking de modelos tabulares y el control V6, ofrece el mejor equilibrio interno: mejora AP en 0.0111, reduce el costo 8.68% y disminuye 28.6% la carga de alertas frente a V6. Sin embargo, una de cuatro ventanas temporales pierde 0.0135 AP; por ello A5 se conserva como **candidato exploratorio**, no como reemplazo confirmatorio.

A · conservar

Mejor ranking y operación promedio.

B/C · no promover

B no demuestra orden; C falla su hipótesis.

D · control

Detecta rareza, pero genera demasiadas falsas alarmas.

Fuente del conjunto de datos. IEEE Computational Intelligence Society. (2019). *IEEE-CIS Fraud Detection* [Data set]. Kaggle; datos anonimizados proporcionados por Vesta Corporation.

<https://www.kaggle.com/competitions/ieee-fraud-detection/overview>

1 · Datos, EDA y protocolo temporal

La

credibilidad del resultado depende de respetar el tiempo, separar decisiones y evitar que el futuro participe en el entrenamiento.

Conclusión. Se utiliza la población completa de IEEE–CIS. Los identificadores y el tiempo crudo coordinan la evidencia, pero no se introducen como magnitudes predictivas; todas las transformaciones aprendidas se ajustan con pasado.

Fuente, unión y variable objetivo

La fuente oficial es IEEE–CIS Fraud Detection, publicada por IEEE CIS en Kaggle con datos anonimizados de Vesta Corporation. `train_transaction.csv` y `train_identity.csv` se unen por `TransactionID`; `isFraud` es el objetivo. Las 590,540 filas incluyen 20,663 fraudes, una prevalencia de 3.50% que vuelve engañosa la exactitud como métrica principal.

Orden y prevención de fuga

Las filas se ordenan por `TransactionDT`. `TransactionID` solo alinea tablas y `TransactionDT` define el reloj; ninguno se usa como número predictor. Imputación, codificación de frecuencias, asociación con fraude, selección, Spearman, PCA, calibración y umbrales se aprenden únicamente dentro del bloque autorizado.

Representación causal

Para una transacción t , cada agregado satisface

$$x_t^{hist} = f(\{x_j : t_j < t\}).$$

Se calculan frecuencia previa de tarjeta/contexto, recencia, monto relativo, faltantes y resúmenes C/D/V/identidad. El

evento actual nunca contribuye a su propio historial.

Inventario, correlación y PCA

La ingeniería V7 produce 465 columnas y retiene 460 candidatas. Spearman elimina 34 representantes por redundancia extrema ($|\rho_s| \geq 0.995$), dejando 426. PCA se limita al bloque V1–V339: 70 componentes explican 90% y 105 explican 95%. La compresión se valida predictivamente porque varianza preservada no equivale a señal de fraude.

Identidad secuencial

Se diagnostican cuatro proxies: tarjeta+dirección y variantes con correo, dispositivo o producto. Estas claves pueden fusionar personas distintas o fragmentar una misma persona; por eso la ausencia de valor del orden se atribuye al experimento observado, no a todas las secuencias financieras posibles.

Deriva temporal

Tres refits walk-forward, cada uno con preprocesamiento reaprendido, obtienen AP 0.599, 0.466 y 0.603. La amplitud de 0.137 muestra que el proceso cambia con el tiempo y justifica un gate de estabilidad además del resultado promedio.


Bloques cronológicos y única función de cada bloque

Bloque	Fracción	Decisión permitida	Control contra fuga
Train	70% total	Preprocesamiento y modelos base	No observa validación
Early	0–35% val	Early stopping	Anterior al metamodelo
Meta fit	35–50% val	Stacking A5 y fusiones C	Usa predicciones fuera de tiempo
Model select	50–60% val	Seleccionar A y C	No calibra ni fija umbral
Calibración	60–70% val	Calibrar probabilidades	Separado del umbral
Umbral	70–80% val	Minimizar costo con recall $\geq .75$	Regla congelada
Evaluación	80–100% val	Aplicar gates y emitir veredicto	No reajusta componentes
Benchmark	15% total	Comparación histórica descriptiva	No decide V7

Advertencia metodológica. El 15% final fue observado durante V1–V6. Una afirmación confirmatoria exige una cohorte futura etiquetada y congelada antes de volver a optimizar.

columnas, menor dimensionalidad o una biblioteca distinta no son mejoras por sí mismas: cada alternativa debe demostrar señal fuera del período que la ajustó.

Modelo	Diseño	Pregunta que responde	AP select
A0	Regresión logística · 100 variables	¿Existe una frontera lineal competitiva?	0.286
A1	LightGBM · variables ampliadas	¿La información completa añade señal?	0.569
A2	LightGBM · $ \rho_s < 0.995$	¿Eliminar redundancia extrema mejora?	0.576
A3	LightGBM · PCA V (128)	¿Comprimir el bloque anónimo conserva fraude?	0.513
A4	CatBoost · categóricas nativas	¿El tratamiento categórico nativo ayuda?	0.428
A5	Stacking A0–A4 + control V6	¿Las señales aisladas son complementarias?	0.628



Correlación. A2 supera levemente A1 durante selección, pero su ventaja aislada no se sostiene en la evaluación común. El filtro se interpreta como control de redundancia, no como criterio automático de relevancia.

PCA. A3 pierde 0.063 AP respecto de A2 en selección. PCA optimiza varianza reconstruida y puede diluir una frontera minoritaria; por eso reducir dimensiones no equivale a predecir mejor fraude.

CatBoost. A4 tampoco gana individualmente. Las categorías nativas son apropiadas para el tipo de datos, pero no compensan automáticamente deriva, faltantes o una validación más exigente.

Por qué A5 sí mejora. El metamodelo logístico recibe los logits de A0–A4 y del control V6. Los modelos base se entrenan antes, el stacking se ajusta en `meta_fit` y se compara después en `model_select`. De esta manera, A5 combina señal complementaria sin permitir que el mismo bloque entrene y juzgue al ensamble.

Resultado común y comparación directa con V6


Modelo	AP	ROC	Prec.	Recall	F1	Costo	Alertas/100k	P@1%
A5	0.547	0.913	0.198	0.772	0.315	Q826,800	11,966	0.887
V6 control	0.536	0.901	0.147	0.803	0.249	Q905,340	16,764	0.898

Conclusión. A5 intercambia 3.1 puntos de recall por 5.1 puntos de precisión. El resultado es 78,540 quetzales menos de costo y 4,798 alertas menos por cada 100,000 operaciones, manteniendo recall por encima del mínimo 0.75.

3 · Comparación A/B/C/D y significado de las métricas

El

modelo se juzga como ranking y como política de alertas; ninguna métrica aislada representa toda la decisión.



	AP	Prec.	Recall	F1
A	.547	.198	.772	.315
B	.392	.112	.708	.194
C	.543	.194	.781	.311
D	.217	.054	.743	.101

Lectura inmediata. A y C ordenan el riesgo de forma parecida; A logra mayor pureza y C recupera cinco fraudes adicionales. B queda claramente por debajo. D conserva recall, pero alerta sobre demasiadas operaciones legítimas.

Qué responde cada métrica


Métrica	Interpretación correcta en este proyecto	Lo que no debe concluirse
AP	Calidad del ranking precisión-recall a través de umbrales; la referencia ingenua es la prevalencia 0.035.	No significa que 54.7% de las alertas sean fraude.
ROC-AUC	Probabilidad de ordenar un fraude por encima de una operación legítima al comparar pares.	Puede verse alta aunque existan miles de falsas alarmas.
Precisión	Fracción de alertas que realmente son fraude; A obtiene 19.8%, aproximadamente una alerta correcta de cada cinco.	No mide cuántos fraudes totales fueron recuperados.
Recall	Fracción de fraudes detectados; A identifica 420 de 544 y omite 124.	No representa la carga de revisión humana.
F1	Media armónica entre precisión y recall en el umbral seleccionado.	No incorpora el costo desigual de FP y FN.
Costo	Consecuencia de la política: $Q4,200FN + Q180FP$.	Depende de supuestos académicos que deben validarse en operación.

Errores observados en la evaluación interna

Modelo	TP	FP	FN	TN	Alertas/100k	Costo	Lectura operacional
A	420	1,700	124	15,473	11,966	Q826,800	Mejor equilibrio global
B	385	3,045	159	14,128	19,360	Q1,215,900	Menos fraude detectado y más ruido
C	425	1,768	119	15,405	12,378	Q818,040	Mayor recall; mejora económica insuficiente
D	404	7,034	140	10,139	41,982	Q1,854,120	Cuatro de cada diez operaciones generan alerta

Conclusión. A es el candidato porque domina AP, precisión, F1 y carga operativa. C cuesta 1.06% menos, pero pierde AP, aumenta alertas y no mejora ninguna ventana; la diferencia no satisface su hipótesis previa.

arquitectura secuencial, una fusión o un detector de anomalías se aceptan por evidencia incremental, no por complejidad.



Condición de B	AP
Original · historia 32	0.3915
Permutada · 5 semillas	0.4016±0.0023
Historia 3	0.3847
Historia 8	0.3774
Historia 16	0.3860
Historia 32	0.3915

Criterio falsable. Si B utiliza favorablemente el orden, permutar antecedentes debe reducir AP al menos 0.01. La diferencia original–permutada es −0.0101: ocurre lo contrario.

Qué prueba la longitud

Los recortes 3/8/16/32 se realizan sin reentrenar: miden sensibilidad inferencial del mismo modelo, no el máximo potencial de cada ventana. No aparece un patrón creciente. B contiene señal porque AP 0.392 supera ampliamente 0.035, pero esa señal puede estar en el evento actual o en la composición del historial, no en su orden.

Hipótesis C y resultado

C debía aumentar AP al menos 0.01, reducir costo al menos 5%, conservar recall ≥ .75, limitar alertas a +10% y mejorar tres de cuatro ventanas. C1=A+B gana entre C1/C2/C3, pero frente a A cambia AP −0.0047, ahorra solo 1.06%, aumenta alertas 3.44% y obtiene 0/4 ventanas positivas. **C no se promueve.**


Diseño y resultado D

El encoder–decoder se entrena únicamente con transacciones legítimas y minimiza $\mathcal{L}_{AE} = p^{-1} \sum_j (x_j - \hat{x}_j)^2$. Su error calibrado obtiene AP 0.217, precisión 5.4% y 41,982 alertas/100k. Detecta rareza, pero rareza también incluye faltantes, deriva y operaciones legítimas inusuales. **D permanece como control.**

Pregunta	Resultado observado	Conclusión permitida
¿B aprende señal?	AP 0.392 ≫ prevalencia 0.035	Sí, pero no supera A
¿El orden ayuda?	Permutar eleva AP 0.0101	No hay valor material demostrado
¿Más historia ayuda?	Sin patrón monotónico	No ampliar sin mejorar identidad
¿C complementa?	Pierde AP y 0/4 ventanas	Rechazar hipótesis actual
¿Anomalía equivale a fraude?	D tiene precisión 5.4%	No; D no es clasificador suficiente


Conclusión. El límite secuencial parece estar en la identidad y la representación, no en la capacidad de la red. Hacer B más grande sin cambiar esa evidencia aumentaría complejidad, no credibilidad.

umbral transforma un ranking en una política de alertas; el resultado solo es útil si mantiene su ventaja a través del tiempo.



$$C(\tau) = Q4,200\, FN(\tau) + Q180\, FP(\tau).$$

El falso negativo cuesta 23.3 veces el falso positivo. A selecciona $\tau = 0.05000$ bajo recall mínimo 0.75: detecta 420 fraudes, omite 124 y genera 1,700 falsas alarmas. El costo se descompone en Q520,800 por FN y Q306,000 por FP. Frente a V6, A5 reduce costo Q78,540 y elimina 833 falsas alarmas en el bloque interno, aunque omite 17 fraudes adicionales. La regla económica considera favorable ese intercambio bajo los costos declarados.



Calibración. El Brier interno de A es 0.0193. Recalibrar no cambia AP si conserva el orden, pero acerca el score a una probabilidad interpretable y hace defendible seleccionar un umbral en un bloque independiente.

Gate temporal. Las diferencias A5–V6 son +0.0244, +0.0070, −0.0135 y +0.0227 AP. Tres ventanas mejoran, pero la tercera viola el límite de caída −0.005. El gate es negativo aunque la media sea positiva.

Benchmark temporal histórico reutilizado

Modelo	AP	ROC	Prec.	Recall	F1	Costo	Alertas/100k
A	0.566	0.918	0.210	0.780	0.331	Q4,477,680	12,938
B	0.465	0.877	0.125	0.784	0.215	Q5,854,920	21,878
C	0.571	0.919	0.205	0.789	0.325	Q4,436,880	13,397
D	0.229	0.769	0.056	0.824	0.105	Q9,969,180	51,061

Lectura honesta del benchmark. A5 supera al control V6 en AP por 0.0064, eleva precisión 5.2 puntos, aumenta F1 en 0.067 y reduce costo Q406,020, con recall 2.8 puntos menor. C luce mejor descriptivamente, pero el benchmark no puede revocar la hipótesis rechazada durante evaluación interna.

Conclusión. V7 mejora utilidad promedio y reduce falsas alarmas. La única conclusión que aún no está respaldada es la superioridad temporal estable; esa afirmación queda pendiente de una cohorte nueva.

6 · Decisión final, evidencia faltante y reproducibilidad

El

cierre distingue con precisión qué se conserva, qué se rechaza y qué observación futura cambiaría el veredicto.

Evidencia	Artefacto verificable	Conclusión	Limitación
Integridad	EDA, protocolo y contrato	590,540 filas; transformaciones train-only	Identidad aproximada
Familia A A/B común	Selección A0–A5 Figura y scores internos	A5 combina señal y mejora el promedio A supera B en AP, precisión, F1 y costo	Una ventana se degrada B se conserva desde V6
Valor del orden	5 permutaciones; 3/8/16/32	Permutar no perjudica; orden no material	Longitudes sin reentrenar
Apuesta C	Regla previa y tres fusiones	C1 no alcanza AP, ahorro ni estabilidad	Familia de fusión limitada
Encoder–decoder	Checkpoint score D	Rareza ofrece recall, no pureza	Normalidad multimodal
Economía	Curvas, umbral y matrices	A5 reduce costo y alertas frente a V6	Costos académicos
Estabilidad	3 walk-forward y 4 ventanas	Deriva material; promoción no confirmada	Sin cohorte futura

Decisión concluyente

Conservar **A5 como candidato exploratorio V7**: presenta el mejor equilibrio interno entre AP, precisión, F1, costo y alertas. No afirmar que reemplaza definitivamente V6 porque incumple el gate de estabilidad. No promover B porque no supera A ni demuestra uso favorable del orden; no promover C porque falla su hipótesis previa; no promover D porque su baja precisión multiplica falsas alarmas.

Qué evidencia cambiaría la decisión

1. Repetir una ganancia de al menos 0.01 AP y una reducción mínima de 5% en costo sobre una cohorte futura congelada.
2. Evitar caídas mayores de 0.005 AP en todas las ventanas temporales y documentar deriva de variables, score y umbral.
3. Reemplazar la identidad proxy por una entidad bancaria fiable y observar una caída de al menos 0.01 AP al permutar antecedentes.
4. Validar costos, capacidad diaria, latencia, privacidad, equidad, explicabilidad y monitoreo antes de cualquier uso productivo.

Candidato y límites

Entrada: transacción actual y agregados causales definidos en el contrato. Salida: `risk_score` calibrado y umbral 0.05000. Faltantes y categorías nuevas siguen el preprocesamiento train-only. Las conclusiones están limitadas por anonimización, identidad proxy, costos académicos, reutilización del benchmark y ausencia de auditoría productiva.

Uso de inteligencia artificial

Se utilizó asistencia de IA para estructurar código, revisar consistencia, automatizar entregables y mejorar redacción. Los autores ejecutaron el pipeline y verificaron IDs, particiones, métricas, gates, artefactos y conclusiones; la IA no se emplea como fuente académica.

Referencias APA 7

- IEEE Computational Intelligence Society. (2019). *IEEE-CIS Fraud Detection* [Data set]. Kaggle. <https://www.kaggle.com/competitions/ieee-fraud-detection/overview>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31.
- Saito, T., & Rehmsmeier, M. (2015). The precision–recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>
- Zhou, C., & Paffenroth, R. C. (2017). Anomaly detection with robust deep autoencoders. *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 665–674. <https://doi.org/10.1145/3097983.3098052>

Conclusión. V7 aporta una mejora tabular operativamente útil y una conclusión científica igualmente importante: no hay evidencia de que el orden secuencial añada valor material bajo la identidad disponible, y la superioridad temporal de A5 todavía debe confirmarse.