

Monitoreo transaccional

Selección train-only, orden y decisión económica

Pregunta ejecutiva

¿El orden o una arquitectura secuencial aportan señal incremental frente a un baseline tabular competitivo, y cuánto vale esa diferencia?

	590,540 transacciones	3.50% prevalencia	0.547 AP interna A5	Q826,800 costo interno A5
--	---------------------------------	-----------------------------	-------------------------------	-------------------------------------

Decisión: conservar A5 como candidato exploratorio

A5 combina el control V6 con modelos V7 y mejora AP, precisión, F1, costo y carga de alertas en promedio. No se declara superior de forma estable porque una de cuatro ventanas cae más de 0.005 AP; C no cumple su hipótesis y B no demuestra valor material del orden.

mejora se evalúa con causalidad, transformaciones train-only y un benchmark explícitamente reutilizado.

Conclusión. Se usaron las 590,540 transacciones y la unión completa de IEEE-CIS. IDs y tiempo crudo no son predictores; selección, correlación, imputación y PCA se ajustan solo con pasado.

Fuente y población

La fuente es IEEE-CIS Fraud Detection, publicada en Kaggle con datos anonimizados de Vesta Corporation. Las tablas se unen por TransactionID y se ordenan por TransactionDT. Hay 20,663 fraudes (3.50%).

Inventario

La unión produce 465 columnas después de ingeniería V7. Se retienen 460 variables candidatas; 34 representantes se eliminan únicamente por redundancia extrema ($|\rho_s| \geq 0.995$). TransactionID se usa para alineación y TransactionDT para causalidad, nunca como magnitudes.

Variables causales

Para una transacción t , toda estadística histórica cumple $x_t^{hist} = f(\{x_j : t_j < t\})$. Se añaden frecuencia previa de tarjeta/contexto, monto relativo, recencia, faltantes y resúmenes C/D/V/identidad. El evento actual no entra en sus propios

agregados.

Correlación y PCA

Spearman localiza redundancia dentro de train. PCA comprime solo V1-V339: 70 componentes explican 90%, 105 explican 95%; con 128 no se alcanza 99%. Se valida la señal predictiva porque varianza explicada no equivale a fraude preservado.

Identidad proxy

Se comparan tarjeta+dirección, tarjeta+dirección+correo y variantes con dispositivo/producto. Mayor cobertura no garantiza identidad correcta: las claves pueden mezclar clientes o fragmentar uno, limitando el significado de la secuencia.

Walk-forward


Tres refits con preprocesamiento reaprendido logran AP 0.599, 0.466 y 0.603. La dispersión confirma deriva y justifica exigir estabilidad, no solo una media alta.

Bloques cronológicos del protocolo

Bloque	Fracción	Uso	Control
Train	70% total	Preprocesamiento y modelos base	No observa validación
Early	0-35% val	Early stopping	Anterior a selección
Meta fit	35-50% val	Stacking A5 y C	Predicciones fuera de tiempo
Model select	50-60% val	Elegir A y C	Dos subventanas
Calibración	60-70% val	Probabilidades	Separada del umbral
Umbral	70-80% val	$4200FN + 180FP$, recall $\geq .75$	Regla congelada
Evaluación	80-100% val	Gates y veredicto	No reajusta modelos
Benchmark	15% total	Referencia histórica	No es test ciego

mejor mejora no es un modelo aislado: es un stacking que conserva el baseline fuerte y añade señales complementarias.

Modelo	Diseño	Propósito	AP select
A0	Regresión logística · 100 variables	Control lineal	0.286
A1	LightGBM · variables ampliadas	Sin reducción	0.569
A2	LightGBM · $ \rho_s < 0.995$	Compactar redundancia	0.576
A3	LightGBM · PCA V (128)	Comprimir bloque anónimo	0.513
A4	CatBoost · categorías nativas	Interacciones categóricas	0.428
A5	Stacking A0–A4 + Complementariedad fuera de tiempo control V6		0.628




Resultado de la ablation. A2 supera ligeramente A1 en selección, pero ambos caen en evaluación. PCA pierde señal y CatBoost tampoco gana individualmente. El resultado evita dos conclusiones fáciles pero falsas: “menos variables siempre generaliza mejor” y “categóricas nativas garantizan superioridad”.

Por qué A5 sí ayuda. El metamodelo logístico usa logits de A0–A4 y del control V6, todos generados en períodos posteriores al entrenamiento base. Se ajusta en `meta_fit`; su ventaja se comprueba después. Incluir V6 corrige una omisión inicial y evita descartar el baseline más fuerte.

Evaluación temporal interna común

Modelo	AP	ROC	Prec.	Recall	F1	Costo	Alertas/100k	P@1%
A	0.547	0.913	0.198	0.772	0.315	Q826,800	11,966	0.887
B	0.392	0.853	0.112	0.708	0.194	Q1,215,900	19,360	0.723
C	0.543	0.913	0.194	0.781	0.311	Q818,040	12,378	0.881
D	0.217	0.758	0.054	0.743	0.101	Q1,854,120	41,982	0.497

Conclusión. A5 mejora AP +0.0111 y reduce costo 8.68% frente a V6 en promedio interno, con precisión 19.8% y recall 77.2%. El gate de estabilidad sigue siendo negativo por una ventana.



Falsificación 1 · permutación controlada

Se mantiene la transacción objetivo al final y se barajan solo antecedentes. La diferencia original–permutada es -0.0101 AP: destruir el orden mejora el ranking promedio, opuesto a la caída positiva mínima de 0.01 requerida.

Falsificación 2 · longitud

Los recortes 3/8/16 y la historia completa 32 se evalúan sin reentrenar, por lo que aíslan sensibilidad inferencial, no capacidad óptima de cada longitud. No aparece un crecimiento monotónico; ampliar la ventana no aporta evidencia útil.

Qué sí y qué no significa

B logra AP 0.392, muy por encima de prevalencia: contiene señal. Sin embargo, queda por debajo de A y puede apoyarse en el evento actual o la composición del conjunto histórico, no en su orden. La identidad proxy ruidosa explica por qué más antecedentes pueden añadir mezcla en vez de memoria.		
Pregunta	Resultado	Conclusión permitida
¿B predice mejor que azar?	Sí; $AP \gg 0.035$	B aprende señal
¿B supera A5?	No; pierde 0.156 AP	A es más competitivo
¿B usa favorablemente el orden?	No; permutar eleva AP	No atribuir valor material
¿Más ayuda?	historia Sin patrón monotónico	No aumentar longitud sin mejor identidad

complementariedad y la anomalía se aceptan solo si mejoran ranking, costo y estabilidad bajo reglas previas.

Hipótesis C

C sería útil con $\Delta AP \geq 0.01$, reducción de costo $\geq 5\%$, recall $\geq .75$, alertas $\leq +10\%$ y mejora en tres de cuatro ventanas. Se comparan C1=A+B, C2=A+B+D y C3 condicionada por calidad, historia, monto y faltantes. C1 gana selección con AP 0.638.

Veredicto C

Frente a A, C1 cambia AP en -0.0047 , reduce costo 1.06%, aumenta alertas 3.44% y no mejora ninguna ventana. Aunque su recall es algo mayor, falla AP, ahorro y estabilidad: **C no se promueve**.

Diseño D

El autoencoder aprende solo transacciones legítimas y minimiza $\mathcal{L}_{AE} = p^{-1} \sum_j (x_j - \hat{x}_j)^2$. Su error se transforma en percentil respecto de errores legítimos de referencia y luego se calibra.

Qué obtuvo D


AP 0.217, precisión 0.054 y 41,982 alertas/100k muestran que anomalía no equivale a fraude. Operaciones legítimas raras, deriva y faltantes también reconstruyen mal. D queda como control y entrada opcional de C, no como candidato.

Calibración


Cada score se recalibra en un bloque separado. El Brier de A es 0.0193 interno; calibrar no cambia AP porque preserva el orden, pero permite interpretar el umbral y comparar costo.

Lectura metodológica

El resultado negativo de C es evidencia útil: B/D no añaden señal suficientemente complementaria. Reajustar C con el benchmark violaría el protocolo. La siguiente prueba debe usar predicciones out-of-fold más diversas y una cohorte nueva.



cuesta 23.3 veces FP; por eso el umbral acepta alertas, pero V7 reduce sustancialmente esa carga.



$C(\tau) = Q4,200\, FN(\tau) + Q180\, FP(\tau)$.

A usa $\tau = 0.05000$. Detecta 420 fraudes, omite 124 y produce 1,700 falsas alarmas: Q826,800. Frente a V6 conserva recall superior a 0.75, reduce alertas 28.6% y costo 8.68%.

Gate. AP global mejora 0.0111 y tres de cuatro ventanas son positivas (+0.0244, +0.0070, -0.0135, +0.0227). La tercera cae más de 0.005; el resultado es prometedor, no estable.

Benchmark temporal histórico reutilizado

Modelo	AP	ROC	Prec.	Recall	F1	Costo	Alertas/100k
A	0.566	0.918	0.210	0.780	0.331	Q4,477,680	12,938
B	0.465	0.877	0.125	0.784	0.215	Q5,854,920	21,878
C	0.571	0.919	0.205	0.789	0.325	Q4,436,880	13,397
D	0.229	0.769	0.056	0.824	0.105	Q9,969,180	51,061

Interpretación

AP 0.566 significa un ranking muy superior a la prevalencia 0.035, no que 56.6% de alertas sea fraude. La precisión puntual es 21.0%: aproximadamente una de cinco alertas es positiva. Recall 78.0% implica recuperar casi ocho de diez fraudes. ROC 0.918 mide separación global, pero no cuantifica carga operativa; por eso se acompaña de AP, precisión, alertas y costo.

Comparación honesta

En el benchmark, A5 eleva AP 0.0064, precisión 5.2 puntos, F1 0.067 y reduce costo Q406,020 frente al control V6, con recall 2.8 puntos menor. C luce mejor descriptivamente, pero su hipótesis interna fue rechazada. El benchmark no puede revocar esa decisión.

Conclusión. V7 mejora la utilidad operativa y reduce falsas alarmas; la evidencia de estabilidad todavía es insuficiente para declarar reemplazo confirmatorio.

6 · Matriz de evidencias y decisión final

Cada

afirmación queda vinculada con una prueba, una conclusión permitida y una limitación explícita.

Evidencia	Artefacto	Conclusión	Limitación
Integridad	EDA, protocolo, contrato	590,540 filas; transformaciones train-only	Identidad aproximada
A competitivo	Selección A0–A5	A5 gana selección y mejora promedio interno	Una ventana se degrada
A/B común	Figura 1, scores	A supera B en AP, precisión, F1 y costo	B congelado desde V6
Valor del orden	5 permutaciones; 3/8/16/32	Permutar no perjudica; sin valor material	Recortes sin reentrenar
Apuesta C	Hipótesis y tres controles	C1 no alcanza AP ni ahorro predefinidos	Familia de fusión limitada
Encoder–decoder	Checkpoint/score D	Rareza tiene recall, no pureza	Normalidad multimodal
Economía	Curvas, figura 5	A5 reduce costo/alertas frente a V6	Costos académicos
Estabilidad	3 walk-forward + 4 ventanas	Deriva material; promoción no confirmada	Sin cohorte futura

Decisión concluyente

Conservar **A5** como candidato exploratorio V7 porque presenta el mejor equilibrio interno entre AP, precisión, F1, costo y alertas. No afirmar que V7 reemplaza definitivamente V6: incumple el gate de estabilidad. No promover B porque no supera A ni demuestra uso favorable del orden; no promover C porque falla su hipótesis; no promover D porque su baja precisión multiplica falsas alarmas.

Qué cambiaría la decisión

(1) repetir la ganancia en una cohorte futura congelada; (2) evitar una caída mayor de 0.005 AP en todas las ventanas; (3) obtener identidad bancaria fiable y caída ≥ 0.01 al permutar; (4) que C logre simultáneamente $+0.01$ AP, -5% costo y recall $\geq .75$; (5) sustituir costos académicos por capacidad y costos reales.

Límites y candidato al proyecto final

Datos anonimizados; identidad proxy; benchmark reutilizado; B/D congelados; costo académico; sin auditoría productiva de privacidad, equidad, explicabilidad, seguridad, latencia ni deriva futura. Entrada: transacción y agregados causales definidos en el contrato. Salida: **risk_score** calibrado y umbral 0.05000. Faltantes y categorías nuevas siguen el preprocesamiento train-only.

Uso de inteligencia artificial

Se utilizó asistencia de IA para estructurar código, revisar consistencia, automatizar entregables y redactar documentación. Los autores ejecutaron el pipeline, verificaron IDs, particiones, métricas, gates, artefactos y conclusiones, y deben poder defender las decisiones.

Referencias APA 7

- IEEE Computational Intelligence Society. (2019). *IEEE–CIS Fraud Detection* [Data set]. Kaggle. <https://www.kaggle.com/competitions/ieee-fraud-detection/overview>
- Ke, G., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.
- Prokhorenkova, L., et al. (2018). CatBoost: Unbiased boosting with categorical features. *NeurIPS*, 31.
- Saito, T., & Rehmsmeier, M. (2015). The precision–recall plot is more informative than ROC for imbalanced data. *PLOS ONE*, 10(3), e0118432.
- Zhou, C., & Paffenroth, R. C. (2017). Anomaly detection with robust deep autoencoders. *Proceedings of KDD*, 665–674.

Conclusión. V7 mejora el promedio y la operación, pero el resultado científico principal es más preciso: hay señal tabular complementaria, no evidencia de orden y todavía no hay superioridad temporal estable.