

Conservar A: la secuencia aún no demuestra valor adicional

AUC-PR INTERNA DEL CANDIDATO A

0.545

LightGBM con expertos por producto

La opción tabular ofrece el mejor equilibrio entre ranking, F1, costo y carga de alertas.



COSTO INTERNO A

Q1,067,460

Menor costo entre A, B y C con la política seleccionada.

RECALL A

73.8%

Recuperación alta sin elevar la carga al nivel de B.

EFFECTO DEL ORDEN

-0.0111


Δ AP original-permutada: el signo observado contradice la mejora esperada.

DECISIÓN DE USO

REVISIÓN

Priorizar casos; nunca bloquear ni atribuir fraude automáticamente.


El futuro queda fuera de cada decisión



Tres modelos responden a la misma pregunta



A domina el balance; C no cumple su apuesta



MODELO	AP	RECALL	F1	COSTO
A · LightGBM	0.545	73.8%	0.339	Q1,067,460
B · GRU	0.424	74.9%	0.224	Q1,320,840
C · Fusión	0.542	78.5%	0.284	Q1,072,020

GANANCIA AP DE C

-0.0020

Por debajo del +0.01 predefinido.


REDUCCIÓN DE COSTO C

-0.43%

No alcanza el 5% requerido.

- Veredicto: C no es útil bajo el criterio previo. En el benchmark histórico, A obtiene AP 0.559 y costo Q4,890,000.

Si el orden importara, destruirlo debería perjudicar a B



ESPERÁBAMOS

AP permutada ↓

Los mismos antecedentes en orden incorrecto deberían degradar el ranking.

OBSERVAMOS

AP permutada 0.4355

Media de cinco semillas, desviación 0.0021.

≠

ORIGINAL · 16

0.424

HISTORIA · 8


0.4225

HISTORIA · 3

0.4253

- $\Delta AP_{original-permutada} = -0.0111$. La red puede aprovechar la colección de eventos o variables actuales, pero esta prueba no respalda una contribución material de su orden.

El umbral convierte puntajes en una política de revisión



$$C(\tau) = 4,200 \cdot FN + 180 \cdot FP$$

RELACIÓN DE COSTOS

23.3x

un FN frente a un FP

UMBRAL A

0.0578

UMBRAL B

0.0335

UMBRAL C

0.0390

A · alertas/100k		10,291
B · alertas/100k		17,416
C · alertas/100k		13,921

- A reduce la carga respecto de B y C. El umbral no cambia AUC-PR: cambia cuántas alertas se revisan, cuántos fraudes se recuperan y el costo resultante.

El promedio oculta dónde el modelo es fuerte o frágil

PRODUCTO R**AP 0.807**

Señal relativamente fuerte.

PRODUCTO W**AP 0.290**


Mayor población y ranking más difícil.

HISTORIA = 1**AP 0.696**

Buen ranking aun con un antecedente.

HISTORIA 4-8**AP 0.397**

Segmento que exige investigación.

**1 Priorizar falsos negativos de alto monto**

Revisar patrones por monto, producto, dispositivo y longitud del historial; no limitarse a métricas globales.

2 Monitorear deriva y calibración

La estabilidad del ranking y del umbral debe evaluarse por período; un puntaje no permanece calibrado indefinidamente.

3 Separar alerta de acusación

El sistema ordena casos para analistas. No demuestra fraude, no bloquea pagos y debe permitir revisión y apelación.

4 Reconocer identidad aproximada

La clave tarjeta + dirección puede mezclar o fragmentar entidades; limita cualquier conclusión sobre memoria individual.

Promover evidencia, no complejidad

1

Congelar A

Modelo, calibrador,
contrato y umbral.

2

Nueva cohorte

Confirmación
temporal sin
retuning.

3

Identidad fiable

Cliente o cuenta real,
con privacidad.

4

Costos reales

Capacidad, latencia y
apelaciones.

5

Piloto

Revisión humana y
monitoreo.

CANDIDATO AL PROYECTO FINAL

A · LightGBM V4 + calibración V5

Entrada contractual → puntaje continuo → umbral → cola priorizada → analista. Si una nueva cohorte contradice la evidencia, se reabre la decisión.



CONCLUSIÓN DEFENDIBLE

- **CONSERVAR A**

No migrar a B o C con la evidencia actual

La mejora futura más plausible no es una GRU más grande: es mejor identidad, nueva evidencia temporal, costos reales y una prueba en operación.

- **Uso previsto:** apoyar al analista de riesgo. **Uso excluido:** bloqueo autónomo, culpabilización o decisión sin apelación.