

Conservar A: la secuencia aún no demuestra valor adicional

AUC-PR INTERNA DEL CANDIDATO A

0.536

LightGBM con expertos por producto

La opción tabular ofrece el mejor equilibrio entre ranking, F1, costo y carga de alertas.

Datos causales



Comparación común



Falsificación



Decisión económica

COSTO INTERNO A

Q904,620

Menor costo entre A, B y C con la política seleccionada.

RECALL A

80.3%

Recuperación alta sin elevar la carga al nivel de B.

EFFECTO DEL ORDEN

-0.0101


Δ AP original-permutada: el signo observado contradice la mejora esperada.

DECISIÓN DE USO


REVISIÓN

Priorizar casos; nunca bloquear ni atribuir fraude automáticamente.


El futuro queda fuera de cada decisión



Tres modelos responden a la misma pregunta



A domina el balance; C no cumple su apuesta



MODELO	AP	RECALL	F1	COSTO
A · LightGBM	0.536	80.3%	0.249	Q904,620
B · TCN causal	0.392	71.3%	0.192	Q1,215,540
C · Fusión	0.519	77.4%	0.273	Q898,920
D · Autoencoder	0.217	74.4%	—	Q1,852,080

GANANCIA AP DE C

-0.0170

Por debajo del +0.01 predefinido.


REDUCCIÓN DE COSTO C

0.63%

No alcanza el 5% requerido.

- Veredicto: C no es útil bajo el criterio previo. En el benchmark histórico, A obtiene AP 0.559 y costo Q4,889,400.

Si el orden importara, destruirlo debería perjudicar a B



ESPERÁBAMOS

AP permutada ↓

Los mismos antecedentes en orden incorrecto deberían degradar el ranking.

OBSERVAMOS

AP permutada 0.4016

Media de cinco semillas, desviación 0.0023.

≠

ORIGINAL · 16

0.392

HISTORIA · 8


0.3774

HISTORIA · 3

0.3847

- $\Delta AP_{\text{original-permutada}} = -0.0101$. La red puede aprovechar la colección de eventos o variables actuales, pero esta prueba no respalda una contribución material de su orden.

El umbral convierte puntajes en una política de revisión



$$C(\tau) = 4,200 \cdot FN + 180 \cdot FP$$

RELACIÓN DE COSTOS

23.3x

un FN frente a un FP

UMBRAL A

0.0362

UMBRAL B

0.0319

UMBRAL C

0.0400

A · alertas/100k		16,741
B · alertas/100k		19,761
C · alertas/100k		14,365

- A reduce la carga respecto de B y C. El umbral no cambia AUC-PR: cambia cuántas alertas se revisan, cuántos fraudes se recuperan y el costo resultante.

El promedio oculta dónde el modelo es fuerte o frágil

PRODUCTO R**AP 0.807**

Señal relativamente fuerte.

PRODUCTO W**AP 0.290**


Mayor población y ranking más difícil.

HISTORIA = 1**AP 0.696**

Buen ranking aun con un antecedente.

HISTORIA 4-8**AP 0.397**

Segmento que exige investigación.

**1 Priorizar falsos negativos de alto monto**

Revisar patrones por monto, producto, dispositivo y longitud del historial; no limitarse a métricas globales.

2 Monitorear deriva y calibración

La estabilidad del ranking y del umbral debe evaluarse por período; un puntaje no permanece calibrado indefinidamente.

3 Separar alerta de acusación

El sistema ordena casos para analistas. No demuestra fraude, no bloquea pagos y debe permitir revisión y apelación.

4 Reconocer identidad aproximada

La clave tarjeta + dirección puede mezclar o fragmentar entidades; limita cualquier conclusión sobre memoria individual.

Promover evidencia, no complejidad

1

Congelar A

Modelo, calibrador,
contrato y umbral.

2

Nueva cohorte

Confirmación
temporal sin
retuning.

3

Identidad fiable

Cliente o cuenta real,
con privacidad.

4

Costos reales

Capacidad, latencia y
apelaciones.

5

Piloto

Revisión humana y
monitoreo.

CANDIDATO AL PROYECTO FINAL

A · LightGBM V4 + calibración V6

Fuente: IEEE-CIS Fraud Detection, Kaggle. Entrada contractual → score → umbral → revisión. Una cohorte nueva puede reabrir la decisión.



CONCLUSIÓN DEFENDIBLE

- **CONSERVAR A**

No migrar a B, C o D con la evidencia actual

La mejora plausible es mejor identidad, cohortes nuevas, categorías completas, costos reales y validación walk-forward; no solo una red mayor.

- **Evidencia:** A gana internamente; B no usa favorablemente el orden; C incumple el gate; D confunde anomalía con fraude.