

Mejor promedio; estabilidad todavía insuficiente

A5 reduce costo y falsas alarmas frente a V6, pero una ventana temporal impide declararlo superior de forma confirmatoria.

DECISIÓN EJECUTIVA

A5

Candidato exploratorio V7

Stacking tabular A0–A4 + control V6. Es la opción con mejor equilibrio interno entre ranking, precisión, F1, costo y carga de alertas.

No reemplaza aún a V6: la tercera ventana cae −0.0135 AP y viola el gate de estabilidad.

AP INTERNA

0.547

+0.011 frente a V6

COSTO INTERNO

Q826,800

−8.7%

PRECISIÓN

19.8%

≈ 1 fraude por 5 alertas

RECALL

77.2%

420 de 544 fraudes

Datos: IEEE-CIS Fraud Detection · Vesta Corporation · Kaggle · 590,540 transacciones · prevalencia 3.50%.

El reto no es acertar “legítimo”; es ordenar bien el fraude escaso

TRANSACCIONES

590,540

FRAUDES

20,663

COLUMNAS V7

465

ARCHIVOS UNIDOS

2

transaction + identity



UNIÓN

TransactionID

Alinea las tablas transaccional y de identidad. Se excluye como magnitud predictiva para evitar ruido de identificación.

RELOJ

TransactionDT

Ordena los eventos y define causalidad. No se entrega al modelo como número crudo.

MÉTRICA PRIMARIA

Average Precision

Evalúa el ranking precisión–recall; su referencia ingenua es 0.035, no 0.50.

Fuente oficial: [IEEE Computational Intelligence Society. \(2019\). IEEE-CIS Fraud Detection. Kaggle.](#) Datos anonimizados proporcionados por Vesta Corporation.

Cada decisión usa un bloque distinto y siempre anterior



Early stopping	Meta stacking	Select A/C	Calibra score	Umbral costo	Evalúa gates
-------------------	------------------	---------------	------------------	-----------------	-----------------

TRANSFORMACIONES TRAIN-ONLY

Sin conocimiento del futuro

Imputación, frecuencias, asociación con el objetivo, selección, Spearman y PCA se ajustan solo con entrenamiento. En cada walk-forward se vuelven a aprender desde cero.

Los agregados históricos de una operación utilizan exclusivamente eventos con tiempo anterior.


POR QUÉ SEIS SUBBLOQUES

Separar ajuste de evaluación

El metamodelo no se juzga con los datos que lo entrenaron; la calibración no fija el umbral; el umbral no decide el gate. Esta separación reduce sobreajuste por decisiones repetidas.

El último 15% ya fue observado en V1–V6: se reporta, pero no selecciona V7.

Reducir redundancia ayuda; comprimir varianza no garantiza fraude



VARIABLES CANDIDATAS

460

PAIRES ELIMINADOS

34

$|\rho_s| \geq 0.995$

RETENIDAS

426

PCA 95%

105

componentes V

RESULTADO DE LA ABLATION


A2 selecciona mejor; A3 pierde señal

A2 alcanza AP 0.576 y PCA-128 obtiene 0.513 durante selección. PCA conserva varianza global, no necesariamente la frontera de una clase de 3.5%.

Identidad proxy: cuatro claves pueden mezclar usuarios o fragmentar uno; esta limitación afecta directamente la utilidad de las secuencias.

Seis candidatos; la mejora aparece al combinar, no al reemplazar

AP DURANTE SELECCIÓN



A5: logits A0–A4 + control congelado; metamodelo ajustado en meta_fit.

Núcleo: A tabular · B TCN causal · C fusión A+B(+D) · D encoder–decoder.

A0

Logística

Control lineal y verificable.

A1 / A2

LightGBM

Completo y reducido por redundancia.

A3 / A4

PCA / CatBoost


Ablations dimensional y categórica.

A5

0.628 Stacking

Conserva el baseline fuerte y permite correcciones complementarias.

AP mide ranking; precisión y recall describen la política



MODELO	AP	ROC	PREC.	RECALL	F1	COSTO
A	0.547	0.913	19.8%	77.2%	0.315	Q826,800
B	0.392	0.853	11.2%	70.8%	0.194	Q1,215,900
C	0.543	0.913	19.4%	78.1%	0.311	Q818,040
D	0.217	0.758	5.4%	74.3%	0.101	Q1,854,120

C: ΔAP -0.0047; ahorro 1.1%; 0/4 ventanas positivas. Hipótesis rechazada.

D: precisión 5.4%; anomalía no equivale a fraude.

AP

Ranking P-R; base 0.035.

ROC

Separación global; no carga.

PRECISIÓN

Pureza de las alertas.


RECALL

Fraude recuperado.

COSTO

Consecuencia del umbral.

Si el orden fuera útil, destruirlo debería perjudicar a B



B ORIGINAL

0.3915

MEDIA PERMUTADA

0.4016


± 0.0023

PRUEBA FALSADA

$\Delta AP = -0.0101$

Se exigía una caída positiva ≥ 0.0100 . Barajar antecedentes mejora el AP, por lo que no puede atribuirse valor al orden.

HISTORIAS 3 / 8 / 16 / 32



No existe patrón monotónico; más historial no demuestra más memoria útil.

Menos falsas alarmas, pero una ventana rompe el gate

COSTO A5

Q826,800

REDUCCIÓN VS V6

8.7%

ALERTAS / 100K

11,966

BRIER A

0.0193

ΔAP V7 – V6 POR VENTANA

VENTANA 1

+0.024

ΔAP V7 – V6

VENTANA 2

+0.007

ΔAP V7 – V6

VENTANA 3

-0.014

ΔAP V7 – V6

VENTANA 4

+0.023

ΔAP V7 – V6

Gate no aprobado: tres ventanas mejoran, pero la tercera cae más que el límite -0.005.

DECISIÓN Y SIGUIENTE EVIDENCIA

A5 genera 1,700 FP y 124 FN: Q306,000 por FP y Q520,800 por FN. Reduce Q78,540 frente al control. Se conserva A5 como candidato exploratorio; B no demuestra orden, C falla su hipótesis y D genera demasiadas alertas.

Para promover: repetir $\Delta AP \geq 0.01$ y ahorro $\geq 5\%$ sin caídas temporales en una cohorte futura con identidad y costos reales.

Fuente: IEEE-CIS Fraud Detection · Vesta Corporation · Kaggle.

