

Proyecto 1: Monitoreo transaccional

Detectar lo que el orden revela

Grupo 1 · Sección 30

Wilson Alejandro Calderón Argueta (22018) · Pablo Daniel Barillas Moreno (22193)

Universidad del Valle de Guatemala · Deep Learning y Sistemas Inteligentes · Kevin Recinos

Resumen ejecutivo


Se evaluó si el orden de las transacciones añade valor frente al sistema agregado del Banco del Altiplano. Sobre 590,540 transacciones reales anonimizadas de IEEE-CIS (20,663 fraudes; 3.499%), se compararon A: gradient boosting sobre agregados, B: GRU sobre ocho eventos y C: fusión GRU–agregados. La selección se realizó con validación cronológica y prueba se abrió una vez. El candidato fue **A**. La permutación solo cambió AUC-PR en 0.002; no se atribuye una ventaja material al orden. Conservar A como candidato y no migrar aún a secuencias. El costo usa Q4,200 por FN y Q180 por FP; la extrapolación mensual es un escenario, no una cifra contable.

1. Integridad de datos y protocolo temporal

El origen es la competencia IEEE-CIS Fraud Detection de Kaggle, aportada por Vesta Corporation. Las transacciones cubren 182 días. La entidad se aproxima con `card1+card2+card3+card5+addr1`: permite historial, pero no garantiza identidad perfecta. Cada objetivo usa la transacción actual y hasta siete antecedentes; no usa futuro.

Partición	n	Fraude
Entrenamiento poblacional	413,378	3.517%
Validación	88,581	3.434%
Prueba final	88,581	3.480%

Los primeros 70% del tiempo entrenan, 15% validan y 15% prueban. Normalización, vocabularios, parada, arquitectura y umbrales se ajustan sin prueba. El submuestreo computacional ocurre solo dentro de entrenamiento y conserva todos los positivos; ambos modelos usan la misma muestra.




2. Núcleo A–B y apuesta C

A resume nivel, dispersión, extremos, recencia y diversidad, y usa HistGradientBoosting. **B** codifica diez variables numéricas y seis categóricas por evento mediante embeddings y GRU(32). Ambos generan riesgo continuo. **C** concatena el estado final de B con agregados estandarizados. La hipótesis previa exigió que C aumentara AUC-PR al menos 0.01 y redujera costo al menos 5% frente a B en validación. El cambio observado fue -0.001 y 0.3%; la apuesta fue **no útil según el criterio previo**.

3. Comparación común


Modelo	AUC-PR	Prec.	Recall	F1	Costo test
A	0.429	0.134	0.722	0.226	Q6,193,620
B	0.412	0.154	0.649	0.248	Q6,525,960
C	0.392	0.136	0.671	0.226	Q6,618,900

AUC-PR es principal por el desbalance; precisión, recall y F1 se reportan en el umbral económico propio, fijado con validación. Exactitud no se usa para decidir.




4. Intentos de refutar el valor del orden

Se permutó cinco veces solo la historia, manteniendo la transacción objetivo al final y todos los eventos intactos. B obtuvo AUC-PR 0.412 original y 0.410 ± 0.001 permutada. La permutación solo cambió AUC-PR en 0.002; no se atribuye una ventaja material al orden. La segunda prueba recortó el historial a tres eventos y produjo AUC-PR 0.411. Estas pruebas miden dependencia predictiva, no causalidad ni identidad bancaria perfecta.



5. Umbral, costo y decisión

Se minimizó en validación $C(\tau) = 4200FN(\tau) + 180FP(\tau)$. Para A, el costo de prueba es Q6,193,620, equivalente a Q6,992,041 por 100 mil decisiones. Con 1.4 millones de tarjetas y 12 transacciones mensuales, el escenario escalado es Q1,174,662,919 y el ahorro frente a A es Q0. La prevalencia y el volumen reales deben reemplazar estos supuestos antes de una decisión financiera.



6. Recomendación, errores y límites

Conservar A como candidato y no migrar aún a secuencias. El puntaje debe priorizar revisión, no bloquear automáticamente. Los falsos negativos concentran Q4,200 y los falsos positivos deterioran experiencia y capacidad operativa. Cambiaríamos la recomendación si una clave de tarjeta confiable elimina el efecto, si una cohorte posterior revierte AUC-PR/costo o si revisión no absorbe alertas. Límites: identidad aproximada, anonimización, 182 días, una ventana, costos transferidos, ausencia de latencia, calibración externa, deriva, equidad y piloto humano.

Matriz de evidencias

Evidencia	Ubicación	Conclusión	Limitación
Integridad	Fig. 1, Tabla 1	70/15/15 cronológico; ajustes train-only	Entidad aproximada
Comparación A–B	Fig. 2, Tabla 2	Mismo horizonte y AUC-PR	Historial de 8 eventos
Valor del orden	Fig. 3	Permutación repetida y recorte	Dependencia no implica causalidad
Apuesta C	Sección 2	Criterio fijado antes del test	Mayor complejidad
Economía	Fig. 4	Umbral minimiza costo suministrado	Volumen/prevalencia asumidos
Recomendación	Sección 6	Decisión condicionada	Falta piloto productivo

Referencias

- Cho, K., et al. (2014). *Learning phrase representations using RNN encoder-decoder*. <https://arxiv.org/abs/1406.1078>.
- Fisher, A., Rudin, C., & Dominici, F. (2019). All models are wrong, but many are useful. *JMLR*, 20(177), 1–81.
- IEEE Computational Intelligence Society. (2019). *IEEE-CIS Fraud Detection* [Data set]. Kaggle.
- Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than ROC. *PLOS ONE*, 10(3), e0118432.
- Scikit-learn Developers. (s. f.). *Common pitfalls and recommended practices*. https://scikit-learn.org/stable/common_pitfalls.html.